


33 — PN Cloud: Cohere Embed 4 → S3 Vectors → MCP (บน EC2)

Region: `ap-southeast-1` · ผู้ใช้จำกัด · ไม่มี Fargate
ไม่ใช่ production เต็มชุด ECS 24–27 — ไกลทางลัด 20 แต่ล็อก Embed 4 + S3 Vectors + multi-RAG
ฉบับ PDF: 33-AWS-PN-CLOUD-MINIMUM-COST-PLAN.pdf · เครื่องมือ: 34 · คู่มือ deploy + .env : 35 ·
แพ็คเกจ: `app/infra/pn-ec2/`

การตัดสินใจที่ล็อกแล้ว

รายการ	ค่าที่ใช้
Compute	EC2 1 เครื่อง (Docker Compose) — รัน MCP + webapp/API
Embedding	Cohere Embed 4 บน Bedrock (<code>cohere.embed-v4:0</code>)
Vector DB	Amazon S3 Vectors
ต้นฉบับ / หลาย RAG	S3 หนึ่งบัคเก็ต · หลาย <code>rag_group</code>
ค้น / RAG	MCP บน EC2 (+ OpenAPI) · เลือก <code>rag_group</code> ได้
ขนาด chunk	~4,096 tokens / chunk
นำเข้า	API บน EC2 (+ โค้ดเรียก API เดียวกัน)
ไม่ใช่	ECS Fargate · ALB (ทางเลือก) · RDS/OpenSearch/Neptune



หลาย RAG: `app/infra/pn/rag-groups.yaml` · API `/api/v1/pn/kb/*` · MCP `list_rag_groups` + `retrieve(rag_group=...)`

1. ทำไมเป็น EC2 (ไม่ใช่ Fargate)

	EC2 (แผนนี้)	Fargate (ยกเลิกใน PN)
รัน MCP + webapp	เครื่องเดียว Compose	หลาย task / บริการแยก
เข้าถึง S3 / KB	IAM instance profile	task role
ดูแล	SSH/SSM + Docker — ทีมค้นแบบ 20	ต้องรู้ ECS/ALB

	EC2 (แพลนนี้)	Fargate (ยกเลิกใน PN)
ต้นทุนคงที่	ชัดเจนรายเดือนต่อ instance	จ่ายตาม vCPU-ชม. + มักมี ALB
Deploy แอป	git pull / docker compose up บนเครื่อง	push image → ECS service

PN ใช้ EC2 เป็นทั้ง MCP host, หน้า/API จัดการ Knowledge Base (S3), และ แหล่ง deploy แอป ของโครงการนี้

2. เครื่องมือบนเครื่อง EC2

ชั้น	ที่รัน / บริการ	บทบาท
EC2 (เช่น t3.small หรือ t3.medium)	Amazon Linux 2023 / Ubuntu	host เดียว
Docker Compose	บน EC2	ยกสแตกแอป + MCP
MCP	app/infra/quick/mcp_server.py (:8767)	Quick / Claude Code
Webapp + API	Next.js + FastAPI (Compose)	อัปเดต/ตรวจ/ดูแล S3
S3	บัคเก็ตโครงการ	ต้นฉบับ + multi-RAG prefix
S3 Vectors	index ต่อ rag_group	embedding chunks
Bedrock	Embed 4	ingest + query
IAM instance profile	บน EC2	bedrock:InvokeModel1 , S3, S3 Vectors
HTTPS	nginx บน EC2 + ใบรับรอง (Let's Encrypt หรือ ACM นำเข้า)	ไม่บังคับ ALB
ความลับ	.env บนเครื่อง หรือ Secrets Manager	MCP/API token
งบ	AWS Budgets	เพดาน Bedrock + EC2

มิติเวกเตอร์: ล็อกตอนสร้าง index (เช่น 1024) — เปลี่ยนมิติ = index ใหม่ + re-embed ทั้งคลัง

3. นโยบาย Chunk = ~4,096 tokens

กติกา	ค่า
target_chunk_tokens	4096
overlap_tokens	256-512
top_k ค่าเริ่ม MCP	3 (สูงสุดแนะนำ 5)
งบข้อความต่อคำขอ	~12K tokens (3 × 4096)
Timeout Quick	< 60 วินาที

อย่าคืนทั้งไฟล์ต้นฉบับใน MCP — คืนเฉพาะ chunk + ชื่อแหล่ง + score

4. Ingest และค้น

Ingest — ง่ายสุด = API บน EC2

```
POST /api/v1/pn/kb/upload (+ rag_group)
  → S3 sources/ + manifest + verify
  → (ขั้นถัดไป) chunk 4096 → Embed 4 → S3 Vectors
```

วิธี	ใช้ใหม่
API บน webapp (EC2)	แนะนำ
โค้ดเรียก API เดียวกัน	ได้
Direct AWS SDK	ได้ แต่ยากกว่า
MCP	ไม่ใช่ ingest

ค้น — MCP บน EC2

```
list_rag_groups → เลือก id
retrieve(query, rag_group=...) → Embed 4 → S3 Vectors → ขึ้นข้อความ
```

Amazon Quick ซี `https://<ec2-หรือ-โดเมน>/mcp` (nginx proxy ไป :8767)

5. Workflows

A — ติดตั้งครั้งแรก

1. สร้าง EC2 + IAM role (Bedrock + S3 + S3 Vectors) + SG (22/SSM, 80/443)
2. สร้าง S3 + S3 Vectors index ต่อ rag_group
3. เปิด Bedrock → cohere.embed-v4:0
4. ติดตั้ง Docker • clone รีโป • docker compose up (webapp + MCP + deps ที่ต้องใช้)
5. ตั้ง nginx HTTPS • Budgets • allow-list ผู้ใช้
6. Sync คลังเริ่มต้น • batch ingest
7. ต่อ Amazon Quick → `https://.../mcp`
8. ทดสอบ upload API + retrieve MCP

B — Deploy / อัปเดตแอปบน EC2

```
SSM หรือ SSH → git pull → docker compose build/up -d
(หรือ CI ไปยัง EC2 ที่หลัง – ไม่ใช่ Fargate)
```

C — เพิ่มเอกสาร / ค้นประจำวัน

6. ประเมินต้นทุนใหม่ (ไม่มี Fargate)

ตัวเลข order-of-magnitude ใน **ap-southeast-1** — ตรวจ Pricing Calculator ก่อนจัดซื้อ

6.1 Compute (แทน Fargate + ALB)

ตัวเลือก EC2	ประมาณ On-Demand / เดือน*	เหมาะเมื่อ
t3.small (2 vCPU / 2 GB)	~\$15–20	MCP + API เบา ๆ, ผู้ใช้จำกัด
t3.medium (2 vCPU / 4 GB)	~\$30–40	webapp + MCP + Compose หลายบริการ
EBS gp3 ~30–50 GB	~\$3–5	ดิสก์ระบบ
Elastic IP (ติดเครื่อง)	\$0	
nginx HTTPS บนเครื่อง	\$0	ไม่เปิด ALB

*ยังไม่รวม Savings Plans / Reserved — จอง 1 ปีมักถูกกว่า

เทียบของเก่า (ยกเลิกใน PN): Fargate เล็ก + ALB มัก ~\$20–40/เดือน และดูแลคนละแบบ — ย้ายมา EC2 เครื่องเดียวต้นทุนคงที่ใกล้เคียงหรือถูกกว่าเมื่อไม่จ่าย ALB

6.2 ข้อมูล + AI (เหมือนเดิม)

รายการ	ประมาณการ
Cohere Embed 4	~\$0.12 / 1M tokens
Seed 10M tokens	~\$1.20
Seed 500M tokens	~\$60
Query 10k×~100 token/เดือน	~\$0.12
S3 ต้นฉบับ	น้อยตอนเริ่ม
S3 Vectors ~1 TB	~\$60 / เดือน
S3 Vectors ~2 TB	~\$120 / เดือน

6.3 รวมแนวโน้มรายเดือน

สถานการณ์	ประมาณการ (ไม่รวมเซต Quick หนัก)
ปี 1 — EC2 t3.small + คลังยังเล็ก	~\$25–50 / เดือน
ปี 1 — EC2 t3.medium + ใช้งานปกติ	~\$40–70 / เดือน
ปี 2 — + S3 Vectors ~1 TB	~\$90–160 / เดือน
ปี 2 — + ~2 TB	~\$150–220 / เดือน

งบประมาณเร็วสุดยังเป็น **LLM แหะของ Amazon Quick** ไม่ใช่ EC2 หรือ embed ค่าถามสั้น

6.4 สิ่งที่ต้องออกจากงบ PN

- ECS Fargate (CPU/RAM-ชม.)
- ALB (ถ้าใช้ nginx บน EC2)
- NAT Gateway หลายตัว (ถ้า EC2 อยู่ public subnet + SG เข้ม — PN ยอมได้; หรือใช้ VPC endpoint S3/Bedrock ลด outbound)

7. ความปลอดภัย (administrative)

- SG: เปิด 443 เฉพาะ IP สำนักงาน / VPN · SSM แทนการเปิด SSH กว้าง
- IAM instance profile จำกัด ARN โมเดล Embed 4 + บัคเก็ตโครงการ
- ผู้ใช้ webapp allow-list · MCP auth จาก Secrets หรือ env
- บัคเก็ต Block Public Access + SSE-KMS
- AWS Budgets เตือน EC2 + Bedrock

8. เกณฑ์ผ่าน

- [] EC2 ขึ้น Compose: webapp + MCP healthy
- [] IAM จากเครื่องเรียก Embed 4 + S3 ได้
- [] POST /api/v1/pn/kb/upload เก็บ+ตรวจบน S3 ตาม rag_group
- [] MCP list_rag_groups + retrieve(rag_group=...) ผ่าน HTTPS
- [] Quick ต่อ MCP ได้ < 60s · ได้แหล่งเอกสารจริง
- [] Chunk ≤ 4096 tokens · ไม่มี Fargate ในสแตก PN

สรุปหนึ่งหน้า

หัวข้อ	คำตอบ
Compute	EC2 + Docker Compose (ไม่มี Fargate)
รันอะไรบน EC2	MCP + webapp/API จัดการ KB/S3 (+ deploy แอป)
Embedding	Cohere Embed 4
Vector DB	S3 Vectors (หลาย index / rag_group)
Ingest	API บน EC2
ค้น	MCP บน EC2 เลือก rag_group
งบปี 1 (คร่าว ๆ)	~\$25-70 / เดือน ตามขนาด EC2
งบปี 2 (+1 TB เวกเตอร์)	~\$90-160 / เดือน