

# 34 — เครื่องมือ AWS ที่ต้องใช้ (PN) — EC2 ไม่มี Fargate

คู่กับแผน 33 · คู่มือ deploy 35 · Region: `ap-southeast-1`  
PDF: [34-AWS-PN-TOOLS-LIST.pdf](#)  
แพ็คเกจ EC2 + `.env` : `app/infra/pn-ec2/` ( `cp .env.example .env` )

## ต้องมี

| เครื่องมือ                 | ใช้ทำอะไร                                        |
|----------------------------|--------------------------------------------------|
| EC2 (t3.small / t3.medium) | รัน MCP + webapp/API ด้วย Docker Compose         |
| S3                         | ต้นฉบับ · หลาย <code>rag_group</code> ได้ prefix |
| S3 Vectors                 | embedding ต่อกลุ่ม                               |
| Bedrock (Cohere Embed 4)   | ฝั่งตอน ingest และตอนค้น                         |
| IAM instance profile       | สิทธิ์จาก EC2 → Bedrock/S3                       |
| Security Group             | จำกัด 443 / SSM                                  |
| Budgets                    | คุมงบ                                            |

HTTPS: **nginx บน EC2** (ไม่บังคับ ALB)  
ความลับ: `.env` หรือ Secrets Manager

## ไม่ใช้ใน PN

ECS Fargate · ALB (ยกเว้นหน่วยงานบังคับ) · RDS · OpenSearch · Neptune · EC2 GPU · DocumentDB

## หลาย RAG บน S3 เดียว

```
s3://{bucket}/rags/{rag_group}/sources/...
s3://{bucket}/rags/{rag_group}/manifest/...
```

คอนฟิก: `app/infra/pn/rag-groups.yaml`

## Ingest — API บน EC2 (ง่ายสุด)

```
curl -X POST "https://<ec2-โดเมน>/api/v1/pn/kb/upload" \
-H "Authorization: Bearer $TOKEN" \
-F "file=@ระเบียบบ.pdf" \
```

```
-F "rag_group=procurement-th" \  
-F "ingest=true"
```

ingest=true = เก็บ S3 → chunk ~4096 → Cohere Embed 4 → **S3 Vectors**

หรือฝั่งทีหลัง: POST /api/v1/pn/kb/ingest ด้วย object\_key

ทดสอบค้น: POST /api/v1/pn/kb/search · MCP **ไม่ใช่** ingest

ค้น — MCP บน EC2 (เลือกกลุ่มได้)

```
Quick / Claude Code  
→ https://<ec2>/mcp  
→ list_rag_groups | retrieve(query, rag_group=...)  
→ Embed 4 → S3 Vectors
```

| ชั้น     | เครื่องมือ                                     |
|----------|------------------------------------------------|
| Host     | EC2 + nginx                                    |
| MCP      | retrieve · list_rag_groups · ping · get_health |
| ฝั่ง/ค้น | Bedrock Embed 4 · S3 Vectors                   |

ต้นทุนคร่าว ๆ (ประเมินใหม่)

| รายการ                | / เดือน   |
|-----------------------|-----------|
| EC2 t3.small + ดิสก์  | ~\$18–25  |
| EC2 t3.medium + ดิสก์ | ~\$33–45  |
| Embed 4 (query เมา)   | มัก < \$1 |
| S3 Vectors @ 1 TB     | ~\$60     |
| ปี 1 รวมแนวโน้ม       | ~\$25–70  |
| ปี 2 (+1 TB)          | ~\$90–160 |

ตัด Fargate + ALB ออกจากแผน PN แล้ว — รายละเอียดใน 33 §6

Checklist

- 1. สร้าง EC2 + IAM role + SG
- 2. Docker Compose: webapp + MCP
- 3. S3 + S3 Vectors + Bedrock Embed 4
- 4. nginx HTTPS
- 5. ทดสอบ upload API + MCP retrieve ตาม rag\_group