

35 — พัฒนาและ Deploy PN บน AWS EC2 (MCP + Webapp + S3)

คู่มือที่ละขั้นตอนสำหรับแพ็คเกจ `app/infra/pn-ec2/`
แผนต้นทุน: 33 · รายการเครื่องมือ: 34
คู่มือผู้ใช้ / งานที่ต้องทำเอง / Local→Cloud: 36
ไม่มี Fargate · คลังความรู้ = S3 + S3 Vectors · Embedding = Cohere Embed 4
PDF: สร้างด้วย `python Discussions/_export_pn_plan_pdf.py`

0. สิ่งที่ได้

ชั้น	ที่อยู่
โพลเดอร์ deploy	<code>app/infra/pn-ec2/</code>
ค่าคอนฟิกทั้งหมด	<code>.env</code> (คัดลอกจาก <code>.env.example</code>)
Webapp ร้าง TOR	Compose <code>frontend</code> + <code>backend</code>
MCP	<code>amazon-quick :8767</code> → <code>mcp-rag</code>
คลัง	S3 prefixes ตาม <code>rag-groups.yaml</code>

```
cp app/infra/pn-ec2/.env.example app/infra/pn-ec2/.env
# แก้ changeme_* → bootstrap → HTTPS → sync dataset → Quick
```

1. ตั้งเครื่องมือบน AWS (ทำครั้งแรก)

ทำใน region `ap-southeast-1`

1.1 บัญชีและงบ

- 1. บัญชี AWS (หรือ OU แยก PN)
- 2. **Billing** → **Budgets** เดือน EC2 + Bedrock + S3
- 3. เปิด CloudTrail ในบัญชี prod/PN

1.2 Bedrock

- 1. Bedrock → **Model access**
- 2. เปิดโมเดลแชทที่หน่วยงานอนุมัติ (ใส่ใน `BEDROCK_MODEL_ID`)
- 3. เปิด `cohere.embed-v4:0` → ค่าใน `.env` : `BEDROCK_EMBEDDING_MODEL_ID=cohere.embed-v4:0`

1.3 S3 (ฐานข้อมูลไฟล์คลัง)

1. สร้างบัคเก็ต เช่น `pn-tor-kb-<หน่วยงาน>`
2. Block Public Access ทั้งหมด · เข้ารหัสตามนโยบาย
3. ใส่ชื่อเดียวกันใน `.env` :

```
PN_S3_BUCKET=pn-tor-kb-example
MINIO_BUCKET=pn-tor-kb-example
MINIO_ENDPOINT=s3.ap-southeast-1.amazonaws.com
MINIO_SECURE=true
MINIO_REGION=ap-southeast-1
MINIO_USE_IAM=true
```

โครงสร้าง prefix (อัปเดตมันทีตอน upload / sync):

```
s3://{bucket}/rags/procurement-th/sources/
s3://{bucket}/rags/procurement-th/manifest/
s3://{bucket}/rags/agency-extra/...
```

1.4 S3 Vectors

1. สร้าง index มิติ **1024** ให้ตรง `.env` / `rag-groups.yaml`
2. `procurement-th-embed4-v1`
3. `agency-extra-embed4-v1` (ถ้าใช้กลุ่มสอง)
4. ค่าใน `.env` : `PN_S3_VECTOR_BUCKET=...` และ indexes ใน `rag-groups.yaml` / `PN_S3_VECTOR_INDEX_*`

1.5 IAM สำหรับ EC2

1. สร้าง Role ชนิด EC2
2. แบนนโยบายจาก `app/infra/pn-ec2/iam/ec2-instance-profile.json`
3. แทน `changeme-pn-tor-kb` ด้วยชื่อบัคเก็ตจริง
4. Attach เป็น **instance profile** ของเครื่อง EC2
5. บน `.env` ของ EC2: เวิร์ว `AWS_ACCESS_KEY_ID` / `AWS_SECRET_ACCESS_KEY`

1.6 EC2

1. AMI Amazon Linux 2023 หรือ Ubuntu 22.04
2. Instant type: **t3.small** (เบา) หรือ **t3.medium** (webapp+MCP สมายกว่า)
3. Disk $\geq$ 30 GB gp3
4. Security Group:
5. inbound **443** จาก IP สำนักงาน/VPN
6. **22** แคมหรือปิดแล้วใช้ **SSM Session Manager**
7. Elastic IP → ใส่โดเมนหรือ hostname ใน `PN_PUBLIC_HOST`
8. ติดตั้ง: Docker + Compose plugin + git + awscli

2. ตั้งค่า `.env` ให้ครบ (ศูนย์กลาง config)

```
cd app/infra/pn-ec2
cp .env.example .env
```

แก้ค่าที่จำเป็นอย่างน้อย:

ตัวแปร	ตัวอย่าง / หมายเหตุ
PN_PUBLIC_HOST	โดเมนหรือ DNS ของ Elastic IP
CORS_ORIGINS	https:// + host เดียวกัน
PN_S3_BUCKET / MINIO_BUCKET	ชื่อบัคเก็ตจริง
JWT_SECRET	ส่ม ≥ 32 ตัวอักษร
QUICK_MCP_AUTH_VALUE	ส่ม — ใส่ใน Amazon Quick ด้วย
POSTGRES_PASSWORD / REDIS_PASSWORD	ส่มบนเครื่อง
BEDROCK_MODEL_ID	โมเดลแชทที่เปิดในบัญชี
BEDROCK_EMBEDDING_MODEL_ID	คง cohere.embed-v4:0

หมวดใน .env.example (อ่านไฟล์นั้นเป็นคำอธิบายเต็ม):

1. AWS region / keys
2. Public host / พอร์ต
3. โหมด cloud
4. Bedrock chat + Embed 4
5. S3
6. multi-RAG / chunk 4096
7. MCP
8. JWT
9. Postgres/Redis บน volume EC2
10. Rate limits
11. Checklist คอนโซล AWS

ห้าม commit .env

3. Deploy บน EC2

```
# บนเครื่อง EC2
git clone <repo> && cd <repo>/app/infra/pn-ec2
cp .env.example .env && nano .env

chmod +x scripts/*.sh
./scripts/bootstrap-ec2.sh

# เปิด reverse proxy
cp nginx/pn.conf.example nginx/pn.conf
docker compose -f docker-compose.pn.yml --profile with-nginx --env-file .env up -d
```

```
# TLS: ใช้ certbot บนโฮสต์แล้ว mount certs ไป nginx/certs (ดู README โฟลเดอร์)
./scripts/healthcheck.sh
```

อัปเดตแอปวันหลัง:

```
git pull
docker compose -f docker-compose.pn.yml --env-file .env up -d --build
```

4. Dataset และ ingest

4.1 สร้างแพ็กเกจบนเครื่อง dev

```
python documents/exports/build_pn_aws_dataset.py --version 0.5.0
# ได้ documents/exports/tor-pn-aws-dataset-v0.5.0.zip
```

แตก zip แล้วใน `.env` บนเครื่องที่มี AWS CLI:

```
PN_DATASET_LOCAL_PATH=/path/to/extracted/rag-pdfs
PN_S3_SOURCES_PREFIX=rags/procurement-th/sources/
```

```
./scripts/sync-dataset-to-s3.sh
```

4.2 อัปโหลดผ่าน API (ง่ายสุดต่อไฟล์)

```
curl -X POST "https://$PN_PUBLIC_HOST/api/v1/pn/kb/upload" \
-H "Authorization: Bearer $TOKEN" \
-F "file=@ระเบียบ.pdf" \
-F "rag_group=procurement-th" \
-F "ingest=true"
```

Pipeline: extract → chunk ~4096 → Bedrock **Cohere Embed 4** → PutVectors บน `PN_S3_VECTOR_BUCKET`
(ข้อความเต็มเก็บที่ `rags/{group}/chunks/...` บน object bucket)

ดึงจากอ็อบเจกต์ที่มีแล้ว:

```
curl -X POST "https://$PN_PUBLIC_HOST/api/v1/pn/kb/ingest" \
-H "Authorization: Bearer $TOKEN" \
-H "Content-Type: application/json" \
-d '{"object_key":"rags/procurement-th/sources/...", "rag_group":"procurement-th"}'
```

5. ต่อ Amazon Quick / Claude Code (MCP)

1. Quick Enterprise → Connectors → **MCP**
 2. URL: `https://$PN_PUBLIC_HOST/mcp`
 3. Auth header = ค่า `QUICK_MCP_AUTH_HEADER` / `QUICK_MCP_AUTH_VALUE`
 4. เรียก `list_rag_groups` แล้ว `retrieve` พร้อม `rag_group`
 5. ต้องตอบภายใน 60 วินาที · [32](#)
-

6. เกณฑ์ผ่าน

- [] `.env` ถูกสร้างจาก `.env.example` และไม่มี `changeme_` ค้างในค่าสำคัญ
 - [] EC2 + IAM + S3 + Bedrock Embed 4 พร้อม
 - [] `docker compose ... up` แล้ว `webapp + MCP healthy`
 - [] Sync หรือ upload ขึ้น S3 เห็นอ็อบเจกต์ได้ `rag/.../sources/`
 - [] `ingest=true` หรือ `/pn/kb/ingest` แล้วมีเวกเตอร์ใน S3 Vectors
 - [] MCP `retrieve` / `POST /pn/kb/search` คืน chunk ตาม `rag_group`
 - [] Quick/Claude เรียก MCP ได้
 - [] ไม่ใช่ Fargate ในสแตกนี้
-

7. อ้างอิงไฟล์

ไฟล์	บทบาท
<code>app/infra/pn-ec2/.env.example</code>	คอนฟิกครบ
<code>app/infra/pn-ec2/docker-compose.pn.yml</code>	สแตกบน EC2
<code>app/infra/pn-ec2/iam/ec2-instance-profile.json</code>	สิทธิ์ AWS
<code>app/infra/pn-ec2/rag-groups.yaml</code>	หลาย RAG
<code>app/infra/pn-ec2/README.md</code>	สรุปสั้นในโฟลเดอร์